Preparação dos dados

Etapa 02 - Plano, justificativas e execução

Radar de Carreira em TI - Grupo 12 - CESAR School
Versão 1.0 - 14 de outubro de 2026

Objetivo: tornar as fontes adequadas às perguntas P1-P12 da fase 01, mantendo origem, unidade de observação, significado das variáveis e limitações. A etapa entrega o plano e um pipeline executado, não resultados de exploração ou modelos.

Fonte e formato bruto	Recorte tratado	Uso e justificativa
Novo CAGED: três .7z com texto UTF-8 separado por ;. Layout oficial XLSX.	Jan-mar/2025: 118.564 movimentos, 62 campos; PE e Nordeste como subconjuntos.	Emprego formal e salário mensal. Famílias CBO delimitam ocupações do Radar.
State of Data: ZIP com CSV, 403 campos originais.	5.215 respostas; base de carreiras com 51 campos.	Perfis em dados, faixas de salário e busca declarada; pesquisa voluntária.
Grupo 12: questionário XLSX e matriz XLSX.	35 respostas/12 perguntas; 21 referências e hipóteses.	Necessidades e intenções; matriz é contexto, não amostra de trabalhadores.
IBGE: municípios e IPCA em JSON.	5.571 municípios; três índices/fatores de IPCA.	Tradução territorial e salários a preços de mar/2025.

Saídas e procedência

CSV UTF-8 com BOM, vírgula, ponto decimal e ausências vazias; Parquet preserva tipos. Nomes de colunas únicos em snake_case, texto NFC e espaços normalizados. Códigos não são números de medida. Nove arquivos brutos têm SHA-256 verificado; versões e produtos constam no relatório de execução.

Os estudos continuam separados. RAIS, PNAD, INEP, Brasscom, Exame e similares são referências da matriz, não bases importadas. A fase 02 não acrescenta dados simulados nem preenche pesquisas ainda não realizadas.

Emprego formal: Novo CAGED

Filtros, categorias e transformações para P1-P4

Variáveis	Decisão aplicada	Justificativa
CBO e área de TI	Famílias 1236/1425/2122/2123/2124/3171/3172; 27 CBOs. Código de seis dígitos, descrição oficial e área analítica.	Escopo explícito, preservando zeros. Inclui automação; não cobre toda carreira possível de TI.
Movimento e competência	saldo 1/-1; calendário derivado; conservar mês do movimento e da declaração.	Contar eventos, não pessoas ou vagas. MOV sem FOR/EXC não é saldo final ajustado.
UF e município	Ligar código CAGED de seis dígitos à chave IBGE única de sete; recortes PE/NE/Brasil.	Evitar duplicação por join e garantir filtros geográficos legíveis.
Salário mensal	Número brasileiro; validade nominal [300,200000]; sinalizar, não remover. Não multiplicar o campo salario por horas/dias.	A unidade do componente fixo não altera o salário mensal do layout; controles não apagam movimentos.
Salário real e faixas	nominal × IPCA(mar/2025)/IPCA(mês). Faixas [0,2000), [2000,4000), [4000,6000), [6000,10000), [10000,15000), [15000,+inf).	Comparar poder de compra; limites claros, sem converter faixa em ponto exato.
Idade e jornada	Idade válida [14,90]; jornada [1,48]. Originais mantidos, sinalizados excluídos apenas de relações/escalas que os usam.	Limites operacionais de plausibilidade, não conclusão legal; idade não é experiência.
Escolaridade e vínculo	Preservar código e texto oficiais; agrupar escolaridade; booleanos anuláveis para indicadores.	Categorias não viram ordem numérica arbitrária; primeiro emprego não equivale a júnior.

Leitura em lotes de 200.000 linhas limita memória. Foram examinadas 13.530.056 linhas brutas. Nenhuma movimentação selecionada é removida por salário sinalizado. As 1.386 linhas iguais sem ID ficam: a fonte não identifica pessoas e podem ser eventos distintos.

Perfis: State of Data

Preparação conservadora para P5-P8

Variáveis	Decisão aplicada	Justificativa
Registro e schema	5.217 respostas originais; remover só duas linhas completamente iguais; IDs preservam linha de origem.	Deduplicação explícita, sem apagar respostas apenas parecidas; ID não liga pessoas a outras fontes.
Gestão, cargo e área	Indicador de gestor como booleano anulável. Gestor declarado sem cargo técnico recebe Gestao.	Correção do erro texto/booleano: 1.045 gestores não devem cair em outra área por falha de tipo.
Senioridade e experiência	Nível apenas declarado. Até dois anos usa experiência em dados; experiência anterior em TI fica separada.	Sem inventar júnior e sem confundir entrada em dados com início de toda a carreira.
Faixa de salário	Guardar texto, limites e exclusividade; faixa acima de R$40.001 permanece aberta.	Não criar salário exato, média por ponto médio ou comparação direta com remuneração administrativa.
Formação, vínculo e trabalho	Categorias por mapeamento explícito, conservando declarações originais na base completa.	Reduzir complexidade visual sem esconder distinções; não informado não é uma categoria de emprego.
Tecnologias e residência	Tecnologias anuláveis; tabela longa só com seleções. Brasil pelo item de residência; regiões por UF.	Nulo não é False. Denominador vem de elegibilidade do item; recortes são subconjuntos.
Busca ativa e proxies	Manter quatro respostas originais e alvo planejado separado; excluir resposta-alvo e proxies próximos no modelo.	Ausente não vira classe negativa; intenção não mede saída futura.

Os 403 campos originais geram 405 colunas com ID/fonte; a versão de carreiras tem 51. Nulos podem decorrer de ramificações, como perguntas não feitas a gestores ou desempregados. Não aplicar complete-case global: avaliar elegibilidade por pergunta e evitar excluir sistematicamente perfis.

Pesquisa própria e matriz

Tratamento de Q01-Q12 e referências para P9-P12

Item	Tratamento aplicado	Justificativa e limite
Schema e coleta	35 respostas; reconhecer número da pergunta, inclusive Q02 no fim. Descartar coluna vazia. Guardar mês, não horário exato, no analítico.	Ordem da exportação não altera semântica. IDs de linha não garantem anonimização.
Q05: nota 1-5	Validar domínio ordinal e preservar notas; não deduzir âncoras/direção.	XLSX não informa o sentido dos extremos; confirmar formulário antes de medir satisfação.
Q07: Sim/Não	Três respostas fora do domínio: original preservado, booleano ausente e flag. Denominador válido = 32.	Não adivinhar intenção nem deslocar respostas para outra pergunta.
Q08: prioridades	Reconhecer sete textos completos; de uma a três seleções. 101 linhas derivadas, não 101 pessoas.	Vírgulas internas não separam opções. Percentual usa participantes que responderam, não total de seleções.
Q09: expectativa	Inteiro mensal; revisão fora de [300,200000] ou não parseável. R$5 mantido e sinalizado.	Não corrigir para milhares nem confundir expectativa com salário recebido; analisar sensibilidade.
Q12: experiência	Anos/meses inequívocos convertidos. Intervalo 7-8 mantém limites e exato ausente; zero válido.	Não transformar intervalo em média ou inventar experiência.
Q10/Q11 e matriz	Sim/Não por item; matriz mantém 21 achados e 10 links, com CSD declarado e alertas.	Emprego/área/regime não equivale ao alvo State of Data. Referência importada não é evidência verificada.

Curso, momento e período permanecem declarados; desperiodizado não vira período zero. O grupo tem tabelas separadas de respostas (35), respostas longas (420) e prioridades (101). Sem cargo padronizado/UF e com coleta em 2026, não medir diferença salarial individual contra o CAGED de 2025.

Nulos, escalas e uso analítico

Elegibilidade e proteção contra vazamento

Uso	Regra	Justificativa
Descrição	Sem imputar média/zero/Não; informar total, válidos, ausentes e exclusões por variável.	Ausência, não aplicável e zero são diferentes; denominador não pode mudar silenciosamente.
Salários CAGED	Usar salario_valido; conservar todos os movimentos nos volumes. Quantis por grupo só com n>=30.	Evitar estatística salarial instável sem apagar contratações; n>=30 não comprova representatividade.
Z-score e min-max	Ajustes do pacote em valores válidos: (x-média)/desvio populacional e (x-min)/(max-min). log1p no salário real.	Escalas exploratórias são separadas dos reais; inválidos permanecem ausentes na tabela de features.
Regressão prevista	Jan/fev treino; março teste. Ajustar codificação/escalas/imputação só no treino; excluir salário nominal, faixas/escalas do alvo e IDs.	Evitar vazamento e medir relação salarial num período reservado, não trajetória da pessoa.
Classificação prevista	State of Data Brasil com alvo respondido; split 80/20 estratificado, semente 12. Excluir alvo, cópias e proxies; não adicionar as 35 respostas G12.	Perguntas e públicos diferentes não aumentam artificialmente o treino; modelo ainda não executado.
Publicação G12	Originais e respostas individuais fora do Git. Revisar consentimento e agregados, células raras e supressão complementar.	Pseudônimo não elimina reidentificação; agregação pequena exige revisão antes de divulgação.

Pendências de confirmação

Permanecem para confirmação: âncoras Q05, três respostas Q07 fora do domínio, expectativa sinalizada, protocolo de recrutamento e autorização de divulgação. A preparação os registra e permite análises restritas; não os resolve por inferência automática.

Pipeline reproduzível

Da fonte verificada ao pacote validado

Passo	Execução e saída
1. Procedência	Verificar nove SHA-256 antes de transformar; origem pública e XLSX próprios têm manifestos separados.
2. Fontes públicas	prepare_datasets.py: schema, survey, CAGED em lotes, dimensões, recortes, agregados e escalas.
3. Pesquisa própria	prepare_grupo12.py: respostas, tabela longa, prioridades, matriz, dicionário e alertas.
4. Validação	validate_package.py: CSV/Parquet em valores, fontes, contagens, relações, deflação, categorias e domínios.
5. Testes e evidência	unittest; execucao_preparacao.json com ambiente, código, fontes, etapas e SHA-256 dos produtos.

Executar na raiz do repositório

```
python -m pip install -r `
inteligencia_de_carreiras/02_preparacao_dados/requirements_reproducao.txt
```

Executar o pipeline completo com os originais locais:

```
python inteligencia_de_carreiras/datasets/scripts/run_preparation.py
```

Para conferir somente o pacote existente, acrescentar --mode validate. O pipeline não baixa dados automaticamente. Em outra máquina, reconstruir o pacote público com download_sources.py e obter os XLSX do grupo por canal autorizado; conferir/registrar os manifestos antes de processar.

Cache e recursos

Cache temporário fora do OneDrive por padrão; --temporary permite escolher outra pasta. Chave inclui o código de transformação e SHA-256 do arquivo CAGED, layout, municípios e IPCA. Mudança de fonte ou regra invalida o reaproveitamento. Temporários não são exports finais nem entram na validação de CSV.

Reservar alguns GB em disco para os textos descompactados; memória é limitada pela leitura em lotes, mas tabelas finais e exports ainda consomem recursos. Sem acesso à internet, os nove brutos já disponíveis permitem reprodução offline. Fontes privadas não são distribuídas pelo Git.

Controles e resultados da preparação

Evidência de execução, não de análise exploratória

Controle	Resultado do pacote revisado
CAGED: população	13.530.056 linhas verificadas; 118.564 movimentos de TI; PE 2.305; Nordeste 10.704.
CAGED: salário e cobertura	690 salários sinalizados; 117.874 válidos. Sem CBO/município sem tradução; 395 jornadas sinalizadas.
CAGED: duplicatas e agregado	1.386 linhas iguais sem ID preservadas; 1.227 grupos conciliados com volumes/quantis e bloqueio n<30.
State of Data	5.217 originais; 5.215 após duas duplicatas exatas; Brasil 5.076. 1.399 senioridades ausentes mantidas.
Correção de gestão	1.045 gestores declarados; 1.045 enquadrados em Gestao quando cargo técnico não respondido. Tipos conciliados com a origem.
Grupo 12	35 respostas/12 perguntas; 420 respostas longas; 101 prioridades; três Q07 fora de domínio; uma expectativa e um intervalo sinalizados.
Matriz de pesquisa	21 itens e 10 links preservados. Certezas, suposições e dúvidas são declarações, não verificação externa.
Rastreabilidade por coluna	582 linhas de decisões na matriz de pré-processamento, incluindo os campos da base completa e dimensões.

Ambiente e execução

Python 3.12.14; pandas 3.0.1, numpy 2.3.5, pyarrow 26.0.0, py7zr 1.1.4, openpyxl 3.1.5. A execução registrada tem modo **full**, com fontes e produtos conferidos. O relatório JSON preserva tempos, versões e hashes sem conteúdo das respostas individuais.

A validação técnica passou com alertas semânticos documentados. Validar estrutura não comprova representatividade, veracidade de relatos ou consentimento. Exploração dos dados e avaliação de regressão/classificação serão executadas nas fases seguintes.

Critérios de aceite e referências

Rastreabilidade da entrega CC02

Critério solicitado	Evidência entregue
Fontes abertas/próprias e formatos	Escopo, formatos e unidades no plano; catálogo, registro e dois manifestos. Sem dados simulados.
Limpeza e normalização	Nomes/tipos/texto, tradução de códigos, domínio, duplicatas, nulos e limites documentados e implementados.
Transformações para análise	Recortes, deflação, faixas, categorias, tabelas longas, agregados e escalas com uso específico.
Justificativa por variável	Matriz CSV com dataset, coluna, tipo, nulos, regra, justificativa e relação com P1-P12.
Reprodução e revisão	Comando único, ambiente registrado, fontes por SHA-256, validação em valores e testes executados.

Referências

Critérios fornecidos pelo grupo: Entregáveis 5ºP - Projeto 2026.1-2, coluna CC Análise e Visualização de Dados. O plano da fase 01 define as perguntas; esta fase justifica como preparar suas variáveis.

MTE: microdados Novo CAGED e layout. Data Hackers: State of Data Brazil 2024-2025. IBGE: IPCA SIDRA tabela 1737/variável 2266 e API de Localidades. URLs, datas e hashes no manifesto público.

Pesquisa e matriz G12: XLSX fornecidos pelo grupo, copiados intactos e registrados em manifesto próprio. Enunciados, hyperlinks e textos originais foram preservados.

Situação da etapa

A etapa 02 está concluída documental e tecnicamente para este pacote, com alertas explícitos. Aprovação acadêmica depende da avaliação da professora. A etapa 03 começará a exploração P1-P12; revisões por confirmação de respostas devem gerar nova versão de fonte/manifesto, não sobrescrever silenciosamente o histórico.