01 Visão Executiva

Radar de carreiras | Documentação final da solução analítica e visual | Grupo 12, Projeto 5, CESAR School | Versão 1.1 | 19/10/2026.

O Radar comunica informações sobre emprego formal em ocupações de TI e perfis de carreira em dados, com foco inicial em Pernambuco e Nordeste. A solução combina preparação reproduzível, análise exploratória, modelos simples e um dashboard em Streamlit. As fontes são apresentadas lado a lado, sem inventar uma população única ou acompanhar pessoas entre bases.

Evidência técnica	Resultado registrado
Testes da aplicação e dos dados	111 aprovados na etapa 07
Verificações no navegador	22 aprovadas em Chromium
Conferência de agregados	65.761 comparações; 0 divergências
Recortes conferidos	4.408 CAGED + 675 State of Data

Estado da entrega: implementação e documentação técnica organizadas nas oito etapas. O dashboard v1.1 funciona localmente e possui evidências funcionais. A documentação final atende ao escopo de CC10: histórico, decisões, capturas e síntese dos insights. Aprovação acadêmica continua sendo atribuição da professora.

Etapa	Resultado
01 - Plano	Perguntas P1-P12, métricas e justificativas visuais
02 - Preparação	Pipeline, regras de limpeza, categorias e rastreabilidade
03 - Exploração	Distribuições, associações e agrupamentos interpretados
04 - Regressão	Comparação temporal, tendências e resíduos
05 - Classificação	Métricas, matriz de confusão, ROC e precision-recall
06 - Dashboard	Quatro visões e proposta de integração/publicação
07 - Consolidação	Correções, auditoria integral e avaliação funcional local
08 - Documentação	Este relatório, índice das entregas e guia de revisão

Pendências externas: revisão estruturada pelos colegas, autorização e execução de commit/push, configuração da hospedagem e teste remoto. Não houve teste formal com participantes nem publicação externa. A impressão positiva informal do solicitante não é tratada como validação de usabilidade.

02 Dados e Preparação

Fonte e unidade	Volume e período	Uso e restrição
Novo CAGED MOV: movimentação formal	118.564 eventos; jan-mar/2025	Salários e fluxos das ocupações selecionadas; pacote público agregado
State of Data: resposta autodeclarada	5.076 residentes no Brasil; 2024-2025	Perfis e busca ativa; amostra voluntária, específica de dados
Pesquisa G12: resposta ao questionário	35 participantes, 12 perguntas; coleta em 2026	Necessidades e intenções; respostas e saídas individuais restritas ao ambiente local
Matriz G12: referência ou hipótese	21 registros documentais, 10 links	Rastreabilidade da pesquisa; não são participantes nem fatos externamente confirmados

O recorte CAGED inclui 27 ocupações de sete famílias CBO e dez áreas analíticas. Foram examinadas 13.530.056 linhas brutas para selecionar os 118.564 eventos de TI. As famílias incluem algumas ocupações de automação e não representam todo o setor de tecnologia. PE e Nordeste são subconjuntos do Brasil, não bases adicionais para somar.

- Preservar códigos como texto e tipos anuláveis; priorizar Parquet. CSV de exportação usa UTF-8 com BOM, vírgula e ponto decimal.

- Usar salário mensal real, corrigido pelo IPCA para março/2025. Não multiplicar remuneração já mensal por horas ou dias.

- Manter os 690 salários CAGED sinalizados nas contagens de movimentos, excluindo-os apenas das estatísticas salariais. Entre admissões, 185 ficam fora da análise de salário.

- Preservar eventos CAGED aparentemente iguais: sem identificador de pessoa ou vínculo não há base para remover essas linhas como duplicatas individuais.

- No State of Data, não transformar ausência em Não ou senioridade ausente em Júnior. Remover somente duas duplicatas integrais identificadas na preparação.

- Calcular quantis diretamente nos eventos elegíveis de cada recorte. Exibir estatísticas salariais e comparações somente com base válida de ao menos 30.

- Não converter faixas salariais autodeclaradas em salários exatos; manter a faixa superior aberta. Tecnologias usam denominadores próprios de resposta ao item.

- Manter alertas do G12 sem inventar correções: três respostas fora do domínio em Q07, uma expectativa sinalizada, intervalo de experiência e âncoras de escala a confirmar.

Catálogo, unidades e volumes

Plano e justificativas de preparação

Registro de fontes e referências ainda não importadas

03 Decisões e Histórico

Fluxo implementado: fontes originais locais, preparação validada, tabelas tratadas por fonte, exploração, modelagem separada, agregados públicos e dashboard. Manifestos e SHA-256 identificam código, insumos e produtos. Os notebooks e relatórios preservam o contexto da etapa em que foram executados; o estado consolidado atual está nesta documentação e na matriz de critérios.

Momento	Decisão e justificativa
Plano e integração	Manter CAGED, State of Data e G12 separados. Unidades, períodos e populações são incompatíveis com uma concatenação de pessoas.
Preparação	Separar contagem de eventos de validade salarial, preservar ausências e documentar categorias derivadas. Não fabricar respostas nem reconstruir informações ausentes.
Exploração	Usar posição, comprimento e eixos comparáveis para contagens e quantis. Agrupamentos são descritivos, não classes naturais de profissionais.
Modelagem	Aprender pré-processamento apenas no treino. Selecionar antes do teste e comparar com referência simples; manter erros e resultados limitados visíveis.
Dashboard inicial	Criar entrypoint próprio na área de inteligência de carreiras e reutilizar a identidade visual, preservando app/, src/, docs/ e notebooks/ históricos.
Consolidação v1.1	Persistir filtros, explicitar o recorte, corrigir o gráfico por ocupação e restaurar padrões explicitamente. Comparar o CSV realmente baixado com o recorte.
Documentação final	Reutilizar evidências verificadas, sem retreinar modelos nem alterar números. Distinguir entrega técnica, feedback de pessoas e hospedagem.

- Hierarquia: marca discreta, navegação previsível, filtros recolhíveis, indicadores e depois gráficos. Quatro visões: Emprego formal, Perfis em dados, Modelos e Fontes.

- Cores: laranja para destaque, neutros para comparação e alertas textuais. Barras começam em zero; percentis aparecem como faixa e mediana.

- Contexto persistente: fonte, período, geografia, ocupação e bases válidas acompanham o resultado. Recortes vazios ou insuficientes têm mensagens próprias.

- Interatividade: filtros por fonte são independentes; filtros exploratórios não alteram treino/teste ou métricas congeladas dos modelos.

Proposta visual e de publicação

Histórico de ajustes e feedback real

04 Síntese dos Insights

Achado observado	Interpretação e limite
Mediana de admissão: PE R$ 3.165; Brasil R$ 3.520.	Salário mensal a preços de março/2025. Diferenças refletem também composição de cargos; não são salário Júnior ou efeito causal regional.
Brasil: 61.047 admissões e 57.517 desligamentos; diferença MOV 3.530. PE: diferença 263.	Contagens incluem salários sinalizados. Sem FOR/EXC, não apresentar a diferença MOV como saldo oficial ajustado.
Idade e salário: Spearman 0,510 em 60.862 pares; jornada e salário: -0,054.	Associação descritiva. Idade não equivale a experiência e não mede crescimento individual ou retorno da formação.
67 perfis UF/área agrupados; k=5 teve silhouette 0,410 entre k=2 e 5.	Perfis cobrem 94,8% das admissões salariais válidas, com peso igual por perfil. Não provar cinco grupos naturais ou ranquear pessoas/regiões.
4.734 respostas salariais válidas em 5.076 residentes no Brasil; faixa modal de R$ 8.001 a R$ 12.000/mês.	Resultado da pesquisa voluntária de dados, não de todo TI. Faixa não vira remuneração exata ou média calculada por ponto médio.
SQL: 87,7% das 3.502 respostas válidas ao item (3.070 seleções).	Tecnologia declarada não mede vagas ou demanda empresarial. Itens têm bases distintas e múltiplas escolhas podem somar mais de 100%.
Busca ativa: 1.630 de 4.734 respostas válidas (34,4%).	As 342 ausências não são negativas. Busca contemporânea declarada não é desligamento futuro ou probabilidade individual de saída.

Implicação para a solução: priorizar filtros por geografia e ocupação, distribuições em vez de promessa de salário individual, bases válidas visíveis e explicações sobre o que cada fonte mede. Achados da pesquisa própria G12 permanecem em saídas locais restritas; não são publicados neste relatório ou incorporados como se fossem novos eventos CAGED.

Síntese pública da exploração

Notebook-fonte da exploração

05 Modelagem e Avaliação

Regressão: 60.862 admissões salariais válidas do CAGED. Escolha por MAE na validação janeiro para fevereiro; treino final com 41.037 eventos de jan-fev e teste reservado com 19.825 de março. Referência: mediana do treino. O modelo múltiplo usa idade, horas, CBO, UF e escolaridade, com Ridge alpha=10 fixo.

Regressor	MAE (R$)	RMSE (R$)	R^2
Mediana do treino	3.734	6.430	-0,168
Linear: idade	3.603	5.479	0,152
Linear: cinco variáveis	2.667	4.307	0,476

O modelo escolhido antes do teste reduziu MAE em 28,6% frente à referência. Foram mantidas 255 previsões negativas (1,3% do teste), expondo a limitação linear. Melhorar o erro agregado não valida uma calculadora salarial pessoal ou previsão de carreira.

Classificação: State of Data, 4.734 alvos válidos; treino/teste estratificados 80/20, semente 12 (3.787/947). Seleção pela Average Precision média em cinco folds somente do treino; logística escolhida, limiar fixo 0,5. Entradas: senioridade, ensino, vínculo agrupado, trabalho e experiência em dados. Pergunta-alvo e variáveis com texto de busca não entram.

Classificador	Acurácia	Precisão	Recall	F1	AUC	AP
Majoritária	65,6%	0,0%	0,0%	0,000	0,500	0,344
Logística	66,1%	53,2%	12,9%	0,207	0,601	0,435
Árvore	64,8%	39,4%	4,0%	0,072	0,579	0,398

Na logística: 42 verdadeiros positivos, 284 falsos negativos, 37 falsos positivos e 584 verdadeiros negativos. O modelo deixa de identificar 87,1% dos positivos. A referência majoritária acerta 65,6%, mas tem recall zero. Portanto, acurácia isolada seria enganosa; não usar os modelos para rotular empregados ou orientar contratação/desligamento.

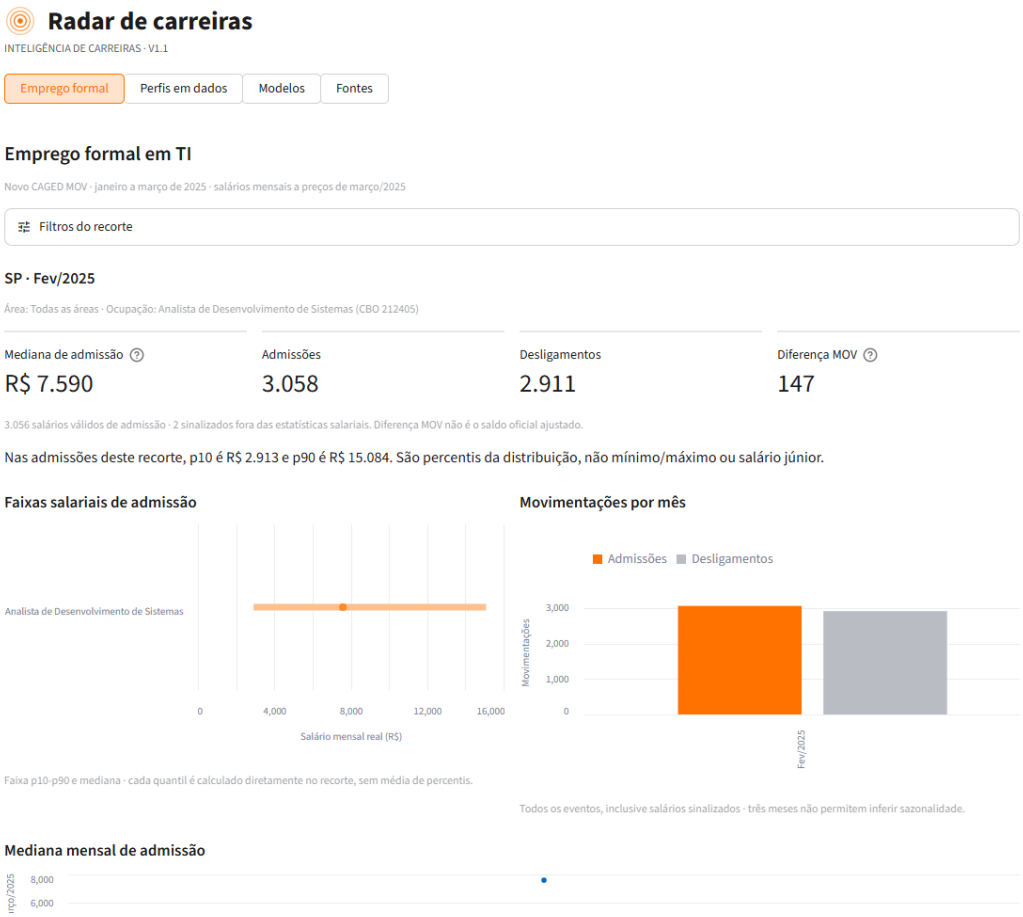
Nenhum teste foi reutilizado para escolher modelo, hiperparâmetros ou limiar. AP não é área trapezoidal genérica da curva PR. São avaliações observacionais: um mês reservado na regressão e uma mesma coleta na classificação, sem validação temporal externa desta última.

Regressão: notebook executado e gráficos

Classificação: notebook executado e gráficos

06 Evidência: Emprego Formal

Captura real da versão 1.1, em desktop 1440x1000. Recorte: SP, fevereiro/2025, CBO 212405 (Analista de Desenvolvimento de Sistemas). O gráfico de faixa salarial acompanha a ocupação, mesmo com Todas as áreas selecionado.



Indicadores, faixa p10-p90 com mediana e volumes mensais. Captura do viewport, não de todo o conteúdo rolável.

- Os números deste recorte são 3.058 admissões, 2.911 desligamentos e diferença MOV 147; a mediana real de admissão é aproximadamente R$ 7.590.

- A identificação do cargo/CBO permanece visível com o painel fechado. P10/p90 não são mínimo/máximo nem remuneração inicial Júnior.

- A consolidação corrigiu um aviso falso de base insuficiente no gráfico de ocupação. O download é comparado ao conteúdo agregado efetivamente filtrado.

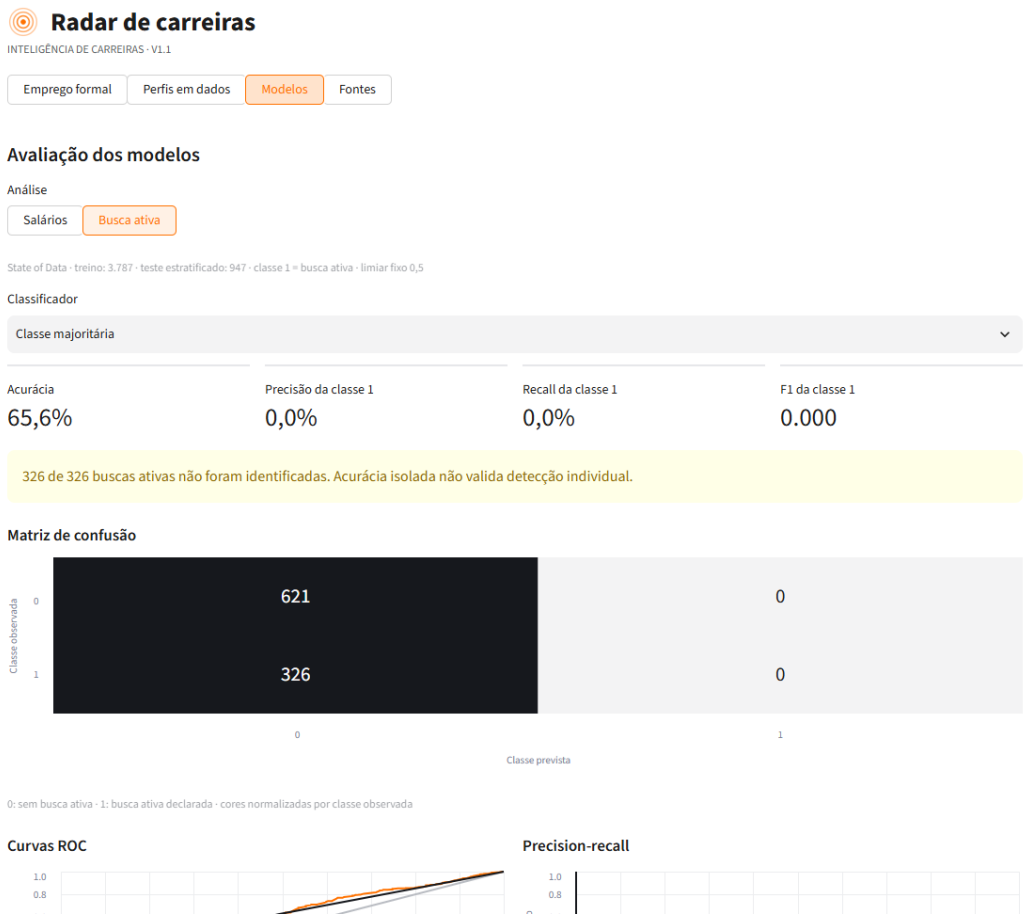
- Filtros ficam na sessão ao trocar de visão. Restaurar filtros usa padrões explícitos e não altera os filtros da outra fonte.

Captura original em resolução integral

Aplicativo implementado

07 Evidência: Modelos

A captura mostra a referência majoritária, não a logística selecionada no treino. Manter a referência visível permite discutir por que acurácia sem recall não valida detecção de busca ativa.



Referência majoritária: 621 negativos corretos, 326 falsos negativos e nenhum positivo identificado. A matriz preserva as contagens; a cor é normalizada por classe observada.

- O seletor compara resultados já calculados, sem retreinar ou escolher pelo teste. Os filtros exploratórios não redefinem a população de avaliação dos modelos.

- A logística é apresentada com recall de 12,9%, e não como solução pronta para decisão individual. Os erros e limites acompanham a comunicação dos resultados.

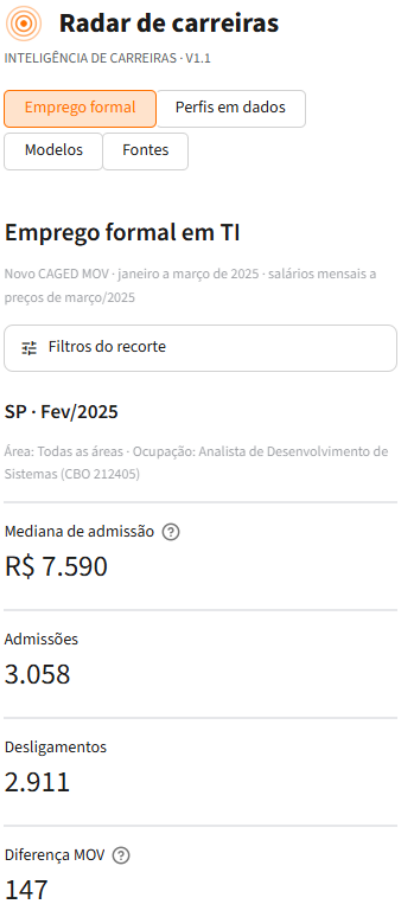
- ROC e precision-recall estão no aplicativo e no notebook executado. A curva PR usa degraus, evitando representar a referência constante como uma diagonal interpolada enganosa.

Captura original em resolução integral

Métricas agregadas de classificação

08 Validação e Telas Menores

Execução técnica da etapa 07: 111 testes aprovados; 22 verificações no Chromium; 65.761 comparações numéricas sem divergências em 5.083 recortes. A etapa 08 confere integridade e documentação, sem declarar novos testes de aplicação ou retreinamento.



Emprego: contexto e indicadores



Perfis após restauração: Brasil

Capturas em 360x800. A bateria ampliada verifica as quatro visões em 360x800, 768x1024 e 1440x1000, incluindo gráficos não vazios e ausência de overflow horizontal. A bateria inicial também cobre 390x844. O QA aguarda a execução real do Streamlit e a atualização visual antes de conferir o recorte.

Composição da execução: preparação 17; exploração 11; regressão 17; classificação 24; dashboard inicial 23; consolidação 19. Os resultados por suite e as versões de ambiente estão nos registros de execução da etapa 06 e da etapa 07.

Verificações cobrem filtros dependentes, persistência, restauração, sessões separadas, estados vazios/insuficientes, CSV realmente baixado, integridade do pacote e seleção básica por teclado. Isso não é certificação de acessibilidade, teste com leitor de tela ou validação em todos os navegadores.

Registro da execução e hashes

Auditoria numérica integral

09 Limites e Melhorias

- Cobertura: CAGED mede emprego formal no recorte de ocupações, não PJ, informalidade ou todo TI. MOV não inclui os ajustes FOR/EXC.

- Tempo: salários a preços de março/2025 e pesquisa 2024-2025 não descrevem remuneração atual de 2026. Três meses não demonstram sazonalidade ou tendência anual.

- Unidade: eventos não são pessoas ou vínculos acompanhados; não inferir promoção, evolução individual ou causalidade por comparar grupos.

- Pesquisa: amostra voluntária e ramificações geram viés de seleção/elegibilidade. Três residentes no Brasil têm UF ausente e não são atribuídos a um estado fictício.

- Modelos: previsões negativas e baixo recall permanecem. Não há validação externa, auditoria de equidade ou autorização para uso em decisões laborais individuais.

- Privacidade: respostas G12, IDs, previsões e escores individuais não entram no pacote público. A regra de n mínimo não prova anonimização universal ou representatividade.

- Referências: RAIS, PNAD, INEP, Base dos Dados, Brasscom e Exame são contexto ou possíveis ampliações, não microdados adicionais já importados neste pacote.

Prioridade	Melhoria e critério de conclusão
Antes da revisão final	Executar o roteiro com colegas; registrar observações reais, decisão, correção e reteste. Ainda não realizado.
Antes da divulgação	Revisar arquivos versionáveis e autorização de envio; depois configurar Streamlit e validar a URL remota.
Próximo ciclo	Avaliar leitor de tela, contraste sistemático e outros navegadores; não afirmar conformidade sem essas verificações.
Ampliação de dados	Adicionar competências/ajustes e novas fontes apenas com cobertura, unidade e procedência documentadas.
Evolução analítica	Validar em outro período/coleta e definir custos de erro antes de mudar limiares ou recomendar uso dos modelos.

Histórico de feedback: o solicitante viu a prévia e achou boa; isso é uma impressão informal real. A revisão estruturada pelos amigos ainda será feita. Melhorias de navegação, gráficos, download e restauração vieram da revisão técnica/visual, não de um estudo com usuários inventado.

Roteiro para revisão real

Registro de feedback e ajustes

10 Reprodução e Entrega

Para abrir o dashboard, basta o repositório com o pacote público agregado; os arquivos brutos, as respostas G12 e os datasets tratados locais não são necessários. Recomendação de ambiente reproduzível: Python 3.12, ambiente virtual e versões fixadas nos requirements.

```
# Na raiz do repositorio, com o ambiente Python ativo
cd inteligencia_de_carreiras/06_dashboard_e_publicacao
python -m pip install -r requirements.txt
python -m streamlit run dashboard.py --global.developmentMode false --server.port 8502
```

Usar outra porta se 8502 estiver ocupada. O endereço local 127.0.0.1 só funciona na máquina que executa o servidor. O envio deste endereço aos colegas não publica o aplicativo. A proposta de hospedagem Streamlit está pronta, mas a implantação externa ainda não foi realizada.

Para reconstruir análises e executar a validação completa, seguir os READMEs das etapas 02-07 com os insumos locais necessários. Não publicar os dados privados para facilitar a reprodução. Para regenerar esta documentação, executar gerar_documentacao.py e validar_documentacao.py nesta pasta; a validação visual do PDF continua sendo uma etapa explícita.

Guia de entrega, evidências CC01-CC10 e checklist

Rubrica original da disciplina

Matriz atualizada de critérios

Plano de análise e decisões visuais

Preparação e reprodução dos dados

Manifesto do pacote público

Proposta de integração e hospedagem

Repositório de origem

MTE: origem dos microdados

State of Data: origem da pesquisa pública

Caminhos de evidência são relativos a esta pasta; o Markdown é o índice navegável no repositório. URLs de origem são referências registradas, não afirmação de checagem online nesta etapa. Este documento não foi submetido à disciplina, enviado aos colegas, publicado, commitado ou enviado ao GitHub automaticamente.